

합성 데이터를 활용한 물류 환경 객체 탐지 모델 학습

Training Object detection model with Synthetic data in Logistic Environments

이지윤¹·정원혁¹·신초희¹·전제환¹·이민호²·정진용³·조영근[†]

Jiyun Lee¹, Wonhyeok Jeong¹, Chohui Shin¹, Jehwan Jeon¹, Minho Lee², Jinyong Jeong³, Younggun Cho[†]

Abstract: With growing interest in logistics automation, object detection in logistics environments has become a critical task. However, collecting diverse image data from real-world logistics environments is costly and challenging. To address this, we generated synthetic data similar to real-world logistics environments using the NVIDIA Isaac Sim. We introduced variations in backgrounds, objects, textures, lighting and camera views to enhance the diversity of the synthetic data for object detection model training. Experimental results show that training models with a combination of real and synthetic images enhances object detection performance compared to training solely on real-world data. Code is available at <https://github.com/iminolee/IsaacSim-Autonomous-Forklift.git>

Keywords: Object Detection, Domain Randomization, Simulation, Isaac Sim


1. 서론

최근 산업 현장에서 물류 자동화에 대한 관심이 높아지면서, 작업자의 노동력에 의존하던 업무를 대체하려는 연구가 진행되고 있다. 자율 주행 지게차와 같은 자동화 시스템에는 물류 객체를 인지할 수 있는 딥러닝 기반 객체 검출 모델이 필요하다. 실제 창고에서 객체 검출 모델을 활용하려면 학습시킬 데이터 셋을 확보해야 한다. 우선, 객체 검출 모델을 위한 실제 학습 데이터 셋은 대량의 데이터와 동시에, 여러 물류 창고의 다양한 환경 변화가 포착된 실제 데이터가 요구된다. 그러나 물류 환경의 보안 문제 및 접근 제한으로 인해 이러한 데이터 셋을 확보하는 것은 어렵다.

이를 위한 대안으로, 합성 데이터를 활용하여 양질의 데이터 셋을 확보하고 객체 탐지 모델을 학습시키는 방법이 있다. 합성 데이터는 물리 엔진 시뮬레이터를 사용하여 비교적 쉽게 취득할 수 있고 여러 환경 변화를 바꿔 생성할 수 있다. 본 논문에서는 NVIDIA Isaac Sim를 활용해 도메인 랜덤화 기법을 적용하여 조명 조건, 객체 위치, 시점 등 실제 환경의 여러 변화를 묘사한 합성 데이터 생성 및 학습을 제안한다.

실험 결과에서 실제 데이터로 학습한 모델은 합성 데이터로, 합성 데이터로 학습한 모델은 실제 데이터로 미세 조정하거나, 두 데이터를 혼합해 학습한 모델의 성능을 확인한다. 실제 데이터로 사전 학습 후, 합성 데이터로 미세 조정된 모델이 가장 우수한 객체 탐지 성능을 보여주며 합성 데이터 추가로 학습하지 않은 실제 창고 환경에서 객체 검출 모델의 성능을 향상시킬 수 있음을 입증한다.

2. 본론



[Fig. 1] The complete flow of synthetic data generation and model training

※ This work was supported by the Starting growth Technological R&D Program(RS-2024-00448695 and RS-2024-00448642) funded by the Ministry of SMEs and Startups(MSS, Korea) and National Research Foundation of Korea(NRF) grant funded by the Korea government(MSIT) (No.2022R1A4A3029480)

1. Undergraduate Student, Inha University, Incheon, Korea,
jywoo6315@gmail.com, rebullu3159@inha.edu,
chohui7876@naver.com, 12200519@inha.edu

2. Master Student, Inha Univ, Incheon, Korea (mino@inha.edu)


3. CTO, TIM Robotics, Seoul, Korea (jinyong.jeong@tim-robotics.com)

† Advisor, Inha University, Incheon, Korea (yg.cho@inha.ac.kr)

[Fig. 1] 는 제안한 합성 데이터 생성 및 학습 과정이다. (a) Isaac Sim에서 제공하는 물류 객체와 3개의 창고 환경을 사용한다. (b) Replicator의 기능 중 도메인 랜덤화와 랜더링을 활용하여 (c) 대량의 합성 데이터 셋을 확보한다. 이를 제한되고 희소한 실제 데이터와 조합하여 YOLOv11 모델로 학습한다. (d) 모델 평가 결과에서 확인된 수정사항을 고려하여 합성 데이터 생성 매개변수를 반복적으로 조정한다.

2.1 합성 데이터 생성

본 연구에서는 실제 데이터로 학습된 객체 탐지 모델이 다양한 환경에서도 일반적인 객체 특징을 반영하도록 하기 위해, NVIDIA Isaac Sim의 Replicator[1] 기능을 활용하여 합성 데이터를 생성한다. 시뮬레이터를 통해 이미지를 생성하여 사람이 데이터 셋에 줄 수 있는 편향을 완화한다. [Fig. 2] 는 합성 데이터 샘플로, 여러 변형이 적용된 물류 환경을 보여준다. 배경, 객체, 텍스처, 조명, 기타 환경 요소 및 카메라 뷰를 무작위로 변화시키는 도메인 랜덤화 기법을 적용하여 학습 데이터의 다양성을 높인다.




[Fig. 2] Synthetic data generated with diverse variations using NVIDIA Isaac Sim's Replicator.

2.2 데이터셋 구축


물류 환경에서 일반적으로 볼 수 있는 객체를 감지하기 위한 모델을 학습하기 위해서 실제 물류 환경에서 취득한 실제 이미지와 Isaac Sim에서 생성된 이미지를 포함하는 데이터 셋을 구축한다. 실제 데이터 셋은 공개된 자원인 LOCO (Logistics Objects in Context)[2]를 활용하며 5개의 다른 물류 환경에서 포착된 이미지와 팔레트, 지게차, 팔레트 트럭, 소형 적재 운반함, 격자형 철재 상자에 대한 5가지 클래스의 라벨 데이터를 제공한다.

생성된 합성데이터는 LOCO와 동일한 클래스를 포함하는 객체들로 구성된다. [Fig. 3] 는 Isaac Sim의 물류 객체들이다. 물류 객체는 각 프레임마다 다양한 크기의 물류 환경에서 무작위 위치에 생성되며, 동시에 객체의 텍스처와 조명 조건

이 변화된다. 이렇게 무작위로 구성된 환경은 실제 사람 또는 로봇의 시점으로 관측 가능한 범위를 제한하고 각 프레임마다 이미지가 포착되어 저장된다. [Fig. 4] 는 사용한 세 가지의 환경 별 합성 데이터를 보여준다. 물류 객체의 텍스처와 위치가 랜덤하게 배치되며 카메라의 시점도 여러 방향으로 변화함을 보여준다.



[Fig. 3] Logistics-specific objects in Isaac Sim assets. Pallets (a), small load carriers (b), stillages (c), forklifts (d) and pallet trucks (e) are common objects within the logistics domain.



[Fig. 4] Synthetic data generated in various environments. Full warehouse at the top, medium warehouse at the bottom left, and small warehouse at the bottom right.

2.3 객체 검출 모델 학습

딥러닝 기반의 객체 검출 모델 시리즈 YOLO(You Only Look Once)의 최신 모델인 YOLOv11[3]을 사용하여 학습한다. YOLO는 이미지 전체를 단일 신경망을 통해 한 번에 처리하는 방식으로, 빠른 처리 속도와 실시간성을 제공한다. 본 논문에서는 YOLOv11s 기반으로 5가지 모델을 학습하여 비교한다. [Table. 1] 는 비교군으로 활용된 모델들에 대한 간단한 설명이다. 모두 동일한 데이터셋과 학습 과정으로 진행한다. 위의 비교 모델 모두 300 에폭과 32 배치 사이즈로 설정하고 학습 시간은 최대 6.5시간 소요되었다.

[Table. 1] Summarize the datasets and training processes used for each model in the experiment

Model	Description
A	합성 데이터로 학습
B	실제 데이터로 학습
C	합성 데이터로 사전 학습 후에 실제 데이터로 미세 조정
D	실제 데이터로 사전 학습 후에 합성 데이터로 미세 조정
E	실제 데이터와 합성 데이터를 혼합 학습

3. 실험 결과


3.1 평가 방법

객체 검출 성능을 평가 시, Precision과 Recall은 각각 모델이 탐지한 객체 중 실제로 올바른 객체의 비율과, 실제 객체 중 모델이 올바르게 탐지한 비율을 의미한다. mAP(mean Average Precision)는 위 두 가지 값을 종합한 지표이다. 본 논문에서는 IoU(Intersection over Union) 임계값이 50% 이상일 때의 mAP를 사용하여 모델의 객체 탐지 성능을 평가한다.

3.2 학습 데이터셋

본 논문에서는 실제 데이터 셋으로 LOCO를 활용하나, 제공하고 있는 학습 및 검증 데이터를 그대로 사용하지 않고 Subset 3를 학습 데이터로, Subset 1과 Subset 2중 일부를 검증 데이터로 사용한다. 각 Subset은 다른 창고에서 촬영된 이미지이며 학습되지 않은 창고 환경에서의 성능을 검증하기 위해 분리하여 구성한다. [Fig. 5] 는 사용한 각 Subset 내 물류 객체의 차이, 서로 다른 카메라로 인한 이미지 품질의 차이, 그리고 세트 간 맥락적 차이를 보여준다.

실제 데이터가 제한적이고 희소성을 가지고 있음을 고려하여 LOCO의 전부 사용하지 않고, 학습 데이터로 873장과 검증 데이터로 Subset 1에서 171장, Subset 2에서 162장을 사용한다. 또한, 2.2절에서 언급한 방법을 통해 합성 데이터 8,128장을 생성하고, 실제 데이터에 합성 데이터를 혼합하여 학습한 경우와 실제 데이터로 학습시킨 모델을 합성데이터로 미세조정된 경우의 성능 향상을 확인한다.




[Fig. 5] LOCO sample images. The figure shows the composition of


different subsets. (a) represents training images used as subset 3, while (b) and (c) show validation data images for subset 1 and subset 2, respectively.

3.3 결과 분석

학습 단계에서는 학습환경을 Intel Core i7-12700K, 64GB RAM, GeForce RTX 3090으로 구성하고 YOLOv11모델을 사용한다. 실험은 LOCO의 각각 다른 창고 환경에서 취득한 실제 이미지인 Subset 1과 Subset 2를 테스트 셋으로 하여 진행하고 위 결과는 [Fig. 6] 와 같다. 합성 데이터와 실제 데이터를 각각 사용한 모델(A, B)과 비교하여 두 가지의 데이터를 모두 활용한 모델(C, D, E)이 전체적으로 더 높은 결과를 보여준다. 또한, [Fig. 7] 과 같이 모든 클래스에서도 동일한 성능 차이를 보인다.




[Fig. 6] The graph shows the mAP50 performance results across five different training configurations




[Fig. 7] The above graph shows the mAP50 performance results per class across five different training configurations

[Fig. 8] 에서 각 테스트 셋인 Subset 1과 Subset 2에 대한 시각적인 추론 결과를 보여준다. [Fig. 8] 의 Subset 1은 팔레트의 객체 검출을 확인하고 Subset 2는 학습되지 않은 복잡한 물류 창고 환경에서 각 모델의 객체 검출 성능을 확인한 결과이다. 모델 B는 두 번의 테스트 모두 Precision이 떨어지는 결



[Fig. 8] Inference results for two test sets: model B trained on LOCO dataset only, model D fine-tuned with synthetic data based on model B, model E trained on the combination of real and synthetic data.

과를 보여준다. 모델 D에서는 다른 클래스 객체와 혼동하지 않으면서 멀리 있는 객체를 감지하고 정확한 위치에 올바른 클래스가 검출된다. 모델 E는 모델 D와 비교하여 오검출과 중복 탐지가 발생한다. [Fig. 9] 는 합성 데이터를 실제 환경과 유사하게 구성하더라도 실제 데이터와 비교 시에 특징 분포의 차이가 있음을 보여준다. 사용한 모든 데이터 셋에서 합성 데이터가 실제 데이터보다 더 넓은 특징 분포를 가진다. 객체 탐지 모델은 초기 학습 단계에서 데이터의 기본적인 특징에 대해 학습하는데 모델 E 학습 시에 실제와 학습 데이터의 비율이 약 1:10으로 합성 데이터가 먼저 선택되어 학습되면 이에 더 편향된 모델이 된다. 모델 D는 실제 데이터가 가지고 있는 특징을 합성 데이터로 미세 조정하여 가장 높은 성능을, 모델 C는 합성 데이터의 특징 분포에 맞춰져 실제 데이터로 미세 조정 후에도 두 가지 데이터를 사용한 모델(C, D, E) 중 가장 낮은 성능을 보인다.



[Fig. 9] Domain shift result for Synthetic data, LOCO subset 2 and 3

4. 결 론

본 연구에서는 도메인 랜덤화를 통해 물류 환경에 대한 합성 데이터를 생성하고 이를 객체 탐지 모델 학습에 활용하는 방법을 제안한다. 실험 결과에서는 실제 이미지와 합성 이미지를 혼합하여 학습한 모델과 실제 이미지로 사전 학습한 모델을 합성 이미지를 사용해 미세 조정된 모델 모두 희소한 실제 데이터만으로 학습한 모델에 비해 객체 탐지 성능이 향상됨을 보여준다. 이는 실제 데이터와 합성 데이터의 조합으로 적절한 도메인 지식을 만들어 객체 탐지 모델을 학습할 수 있다. 합성 데이터를 활용한 모델 학습으로 대량의 실제 데이터를 확보하는 데 따르는 비용과 어려움을 줄이면서도, 모델 성능을 효과적으로 개선할 수 있음을 시사한다.

5. Reference

- [1] NVIDIA Omniverse Replicator Documentation, Available: <https://docs.omniverse.nvidia.com/py/replicator/1.11.16/>, Accessed: [Nov. 6, 2024].
- [2] Mayershofer, Christopher, et al. "Loco: Logistics objects in context." 2020 19th IEEE International Conference on Machine Learning and Applications (ICMLA). IEEE, 2020.
- [3] Glenn Jocher and Jing Qiu. Ultralytics yolo11, Accessed: [Nov.14,2024].